

FIAP
TECNÓLOGO EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

FELIPE RIBEIRO TARDOCHI DA SILVA - RM555100

GUSTAVO DIAS DA SILVA CRUZ - RM556448

JULIA MEDEIROS ANGELOZI – RM556364

Global Solution
Disruptive Architectures - IoT, IOB and Generative

São Paulo
2025

Treinamento do Modelo

O treinamento do modelo de previsão de precipitação foi realizado utilizando um conjunto de dados históricos do Instituto Nacional de Meteorologia (INMET), especificamente da região de São Paulo, abrangendo o período de 2022 a 2024. O processo de treinamento, detalhado no notebook `GSNimbus.ipynb`, seguiu as seguintes etapas principais:

Coleta e Preparação dos Dados

- Os dados brutos foram carregados de um arquivo CSV (`dataset.csv`);
- Foram selecionadas as colunas (features) mais relevantes para a previsão de precipitação: temperatura do ar, umidade relativa, pressão atmosférica, temperatura do ponto de orvalho e velocidade do vento;
- Novas features baseadas em data e hora (mês, dia do ano, hora do dia) foram criadas para capturar padrões sazonais e horários;
- Registros sem ocorrência de precipitação foram removidos, focando o modelo em prever a intensidade em casos com chuva.

Pré-processamento

- As features numéricas foram normalizadas com o `MinMaxScaler` da biblioteca `scikit-learn`, para equilibrar a influência de cada feature no aprendizado;
- Valores ausentes foram removidos para garantir a integridade dos dados.

Divisão dos Dados

- O conjunto foi dividido em 80% para treinamento e 20% para teste, com `train_test_split`.

Construção e Compilação do Modelo

- Utilizou-se uma Rede Neural Artificial (RNA) sequencial com `Keras` (baseada em `TensorFlow`);
- A arquitetura inclui camadas densas (fully connected) com ativação `ReLU`, e uma camada de saída para regressão (previsão da precipitação);
- O modelo foi compilado com o otimizador `Adam`, função de perda `Mean Squared Error (MSE)`, e as métricas `MAE` e `MSE`.

Treinamento e Avaliação

- O modelo foi treinado por um número definido de épocas;
- Avaliado em dados de teste para medir a capacidade de generalização com `MAE` e `MSE`.

Serialização do Modelo

- Após o treinamento, o modelo foi salvo como `modelo_precipitacao.pkl` com `pickle`, permitindo sua reutilização via `API Flask` para previsões em tempo real.

O notebook `GSNimbus.ipynb` contém todo o pipeline, desde a leitura dos dados até o salvamento do modelo.

Integração com a Solução Global

Essa modelagem foi incorporada na solução desenvolvida para o projeto **Global Solution - Disruptive Architectures (IoT, IOB e Generative AI)**, apresentada pelos alunos:

- Felipe Ribeiro Tardochi da Silva - RM555100
- Gustavo Dias da Silva Cruz - RM556448
- Julia Medeiros Angelozi – RM556364

A proposta é uma aplicação que prevê possíveis desastres naturais com base na localização do usuário, enviando alertas classificados em níveis (baixo, médio, grave). O usuário pode cadastrar múltiplas localizações de interesse — como casa, trabalho ou familiares — e receber alertas personalizados para cada local.

A previsão é realizada através de uma API Flask, que recebe os dados processados e retorna a previsão classificada para ser salva no banco de dados e exibida no sistema.

Resultados Obtidos

Considerando está parcela de previsões baseados com os dados reais, podemos observar que o modelo tem sua precisão, porém com algumas falhas, e isso se dá por conta dos dados, que não são dos melhores, fazendo com que o modelo não seja tão assertivo.

```
Valor real: 0.40, Previsão: 2.00
Valor real: 2.80, Previsão: 2.12
Valor real: 1.00, Previsão: 1.99
Valor real: 1.80, Previsão: 3.21
Valor real: 0.40, Previsão: 6.08
Valor real: 0.80, Previsão: 1.76
Valor real: 0.60, Previsão: 1.99
Valor real: 3.60, Previsão: 2.23
Valor real: 0.20, Previsão: 3.62
Valor real: 12.60, Previsão: 11.77
```

Conclusões

Baseado nos dados obtidos, pode-se concluir que é possível utilizar o modelo, porém com certa cautela, por conta da sua acurácia, e que é necessário uma melhoria no dataset utilizado.